



Aplicación de identificación de productos de supermercado

Inteligencia Artificial



Integrantes:



- Kevin Gutierrez
- Sebastian Pomaquiza
- Mateo Barzallo
- Karen Quito

Julio, 2025

Identificación del problema de un centro comercial

Problemática en la Experiencia de Compra

- Falta de información clara sobre los productos en góndolas.
- Demoras al pedir ayuda a empleados para conocer detalles.
- Frustración y pérdida de tiempo, lo que afecta la satisfacción del cliente.
- En alimentos, dificultad para saber cómo usar ciertos ingredientes.
- Personas mayores o con discapacidad visual tienen problemas para leer etiquetas, lo que afecta sus decisiones de compra y bienestar.



Justificación de la importancia de la aplicación

Justificación de la Solución Propuesta

- Se propone una aplicación móvil con un modelo CNN para identificar productos mediante imágenes.
- Reconocimiento rápido y preciso al tomar una foto del producto.
- Acceso inmediato a información detallada, sin necesidad de ayuda del personal.
- Mejora la experiencia de compra: más rápida, autónoma y accesible.
- Incluye recetas relacionadas con productos alimenticios,
- fomentando su uso y promoviendo compras adicionales.

Pasos a desarrollar




- Recolección de datos: Recopilar un conjunto de datos de imágenes de productos.
- Preprocesamiento de datos: Limpiar y preparar los datos para el entrenamiento del modelo, incluyendo la normalización y el etiquetado adecuado.
- Desarrollo del modelo: Implementar una red neuronal convolucional (CNN) para la identificación de productos a partir de imágenes, usando modelos preentrenados como MobileNetV2.
- Entrenamiento del modelo: Entrenar el modelo utilizando el conjunto de datos preparado, ajustando los hiperparámetros según sea necesario.

Pasos para el uso de la aplicación

1. Tomar una foto del producto: El usuario utiliza la cámara de su dispositivo para tomar una foto del producto que desea identificar.
2. Procesamiento de la imagen: La aplicación envía la imagen a un modelo de red neuronal convolucional (CNN) para identificar el producto.
3. Obtener información del producto: Una vez identificado, la aplicación muestra información detallada sobre el producto, incluyendo nombre y otros detalles relevantes.
4. Explorar recetas: Si el producto es alimenticio, el usuario puede explorar recetas relacionadas con ese producto, lo que le brinda ideas sobre cómo utilizarlo en sus comidas.
5. Historial de búsqueda: El usuario puede acceder a un historial de sus búsquedas anteriores para facilitar futuras compras o referencias.

Fundamentos teóricos

- Inteligencia Artificial (IA): Automatiza procesos de reconocimiento visual.
- Machine Learning (ML): Permite a los sistemas aprender de datos sin ser explícitamente programados.
- Deep Learning (DL): Utiliza redes neuronales profundas, especialmente CNN para el análisis de imágenes.



DEEP LEARNING

Metodo de desarrollo

Dataset personalizado.

Se creo un dataset multietiqueta, en donde hay 11 clases.

Por cada clase se tomaron 20 fotos y para robustecer se aumento las imagenes con data augmentation

11 clases de productos:

- Banana
- Orange
- Red-Bell-Pepper
- aluminium-form
- bread
- doritos
- cocaCola
- red-bull
- shampoo-H&S
- tea
- yogurt-toni-mix.

shampoo-H&S



red-bull (más similar)



Red-Bell-Pepper (más distante)




Version 1

Modelo CNN puro

Modelo CNN multietiqueta

- El modelo uso un optimizador Adam, un tamaño de batch de 32 y 15 epoch.
- Los resultados son los siguientes:
 - loss: 0.0625
 - accuracy: 0.8778
 - val_loss: 0.0978
 - val_accuracy: 0.9508




Evaluación por Clase

El modelo logra precisión perfecta, pero el recall es bajo en algunas clases por el desbalance del dataset. Esto indica que no detecta todos los ejemplos correctos. Aun así, el f1-score es alto, reflejando un desempeño aceptable pese al sobreajuste.

	precision	recall	f1-score	support
0	1.00	1.00	1.00	6
1	1.00	1.00	1.00	5
2	1.00	1.00	1.00	5
3	1.00	0.60	0.75	5
4	1.00	1.00	1.00	5
5	1.00	0.67	0.80	9
6	1.00	0.60	0.75	10
7	1.00	0.80	0.89	5
8	1.00	0.60	0.75	5
9	1.00	1.00	1.00	5
10	1.00	1.00	1.00	5

Desempeño del Modelo – CNN V1

La accuracy mejora en ambas fases, pero la validación parte muy alta por tener pocos datos. La loss disminuye, aunque al final sube en validación, señal de posible overfitting causado por el desbalance y validación limitada.



Version 2

Modelo CNN con TransferLearning
Balanceo de Dataset

Transfer Learning y Balanceo de Datos

Se utilizó MobileNetV2 preentrenado en ImageNet como extractor de características. Esto permitió aprovechar conocimiento previo, acelerar la convergencia y mejorar la generalización del modelo sin necesidad de grandes volúmenes de datos.

Se aplicó una función personalizada que selecciona 85 imágenes por clase, logrando una distribución equilibrada.

Esto corrigió el desbalance presente en la versión anterior, reduciendo el sesgo hacia clases con más ejemplos y mejorando el recall por clase.

Evaluación por clase – CNN V2

El modelo logra precision, recall y f1-score perfectos en 10 de 11 clases. Solo en “CocaCola” baja ligeramente a 0.99, lo cual es un resultado excelente.

El promedio micro, macro y weighted es 1.00, lo que demuestra un modelo robusto y balanceado.


REPORTE DE CLASIFICACIÓN:				
	precision	recall	f1-score	support
Banana	1.00	1.00	1.00	24
Orange	1.00	1.00	1.00	20
Red-Bell-Pepper	1.00	1.00	1.00	20
aluminium-form	1.00	1.00	1.00	20
bread	1.00	1.00	1.00	20
cocaCola	0.97	1.00	0.99	36
doritos	1.00	1.00	1.00	36
red-bull	1.00	1.00	1.00	20
shampoo-H&S	1.00	1.00	1.00	20
tea	1.00	1.00	1.00	20
yogurt-toni-mix	1.00	1.00	1.00	20
micro avg	1.00	1.00	1.00	256
macro avg	1.00	1.00	1.00	256
weighted avg	1.00	1.00	1.00	256
samples avg	1.00	1.00	1.00	256

Desempeño del Modelo – CNN V2

El modelo muestra una convergencia rápida y estable. La accuracy en validación se mantiene alta y cercana a la de entrenamiento, lo que indica buena generalización.

La pérdida se reduce de forma continua en ambas fases, sin señales de overfitting.

El learning rate disminuye automáticamente al detectar estancamiento.



Aplicacion

FRONT - END



BACK - END



BASE DE DATOS



Aplicación móvil

Framework:

Flutter: Flutter es un framework de desarrollo de interfaces móviles creado por Google. Permite crear aplicaciones nativas multiplataforma (Android, iOS, web y escritorio) desde una sola base de código usando el lenguaje Dart.

Librerías:

- camera: para tomar fotos directamente desde la app
- dio: para hacer peticiones HTTP a la API de clasificación
- flutter_tts: para lectura de textos en voz alta
- carousel_slider: para mostrar productos detectados en un carrusel



Web Service

Framework:

FastAPI: Framework web moderno y rápido para construir APIs con Python. Fue elegido por su rendimiento, simplicidad y facilidad para trabajar con peticiones HTTP y modelos de datos.

Tecnologías utilizadas

- **FastAPI:** Para construir la API REST
- **Vertex AI:** Para obtener información general del producto
- **Supabase:** Base de datos y almacenamiento para guardar resultados de las peticiones




API de Google Cloud - Vertex IA

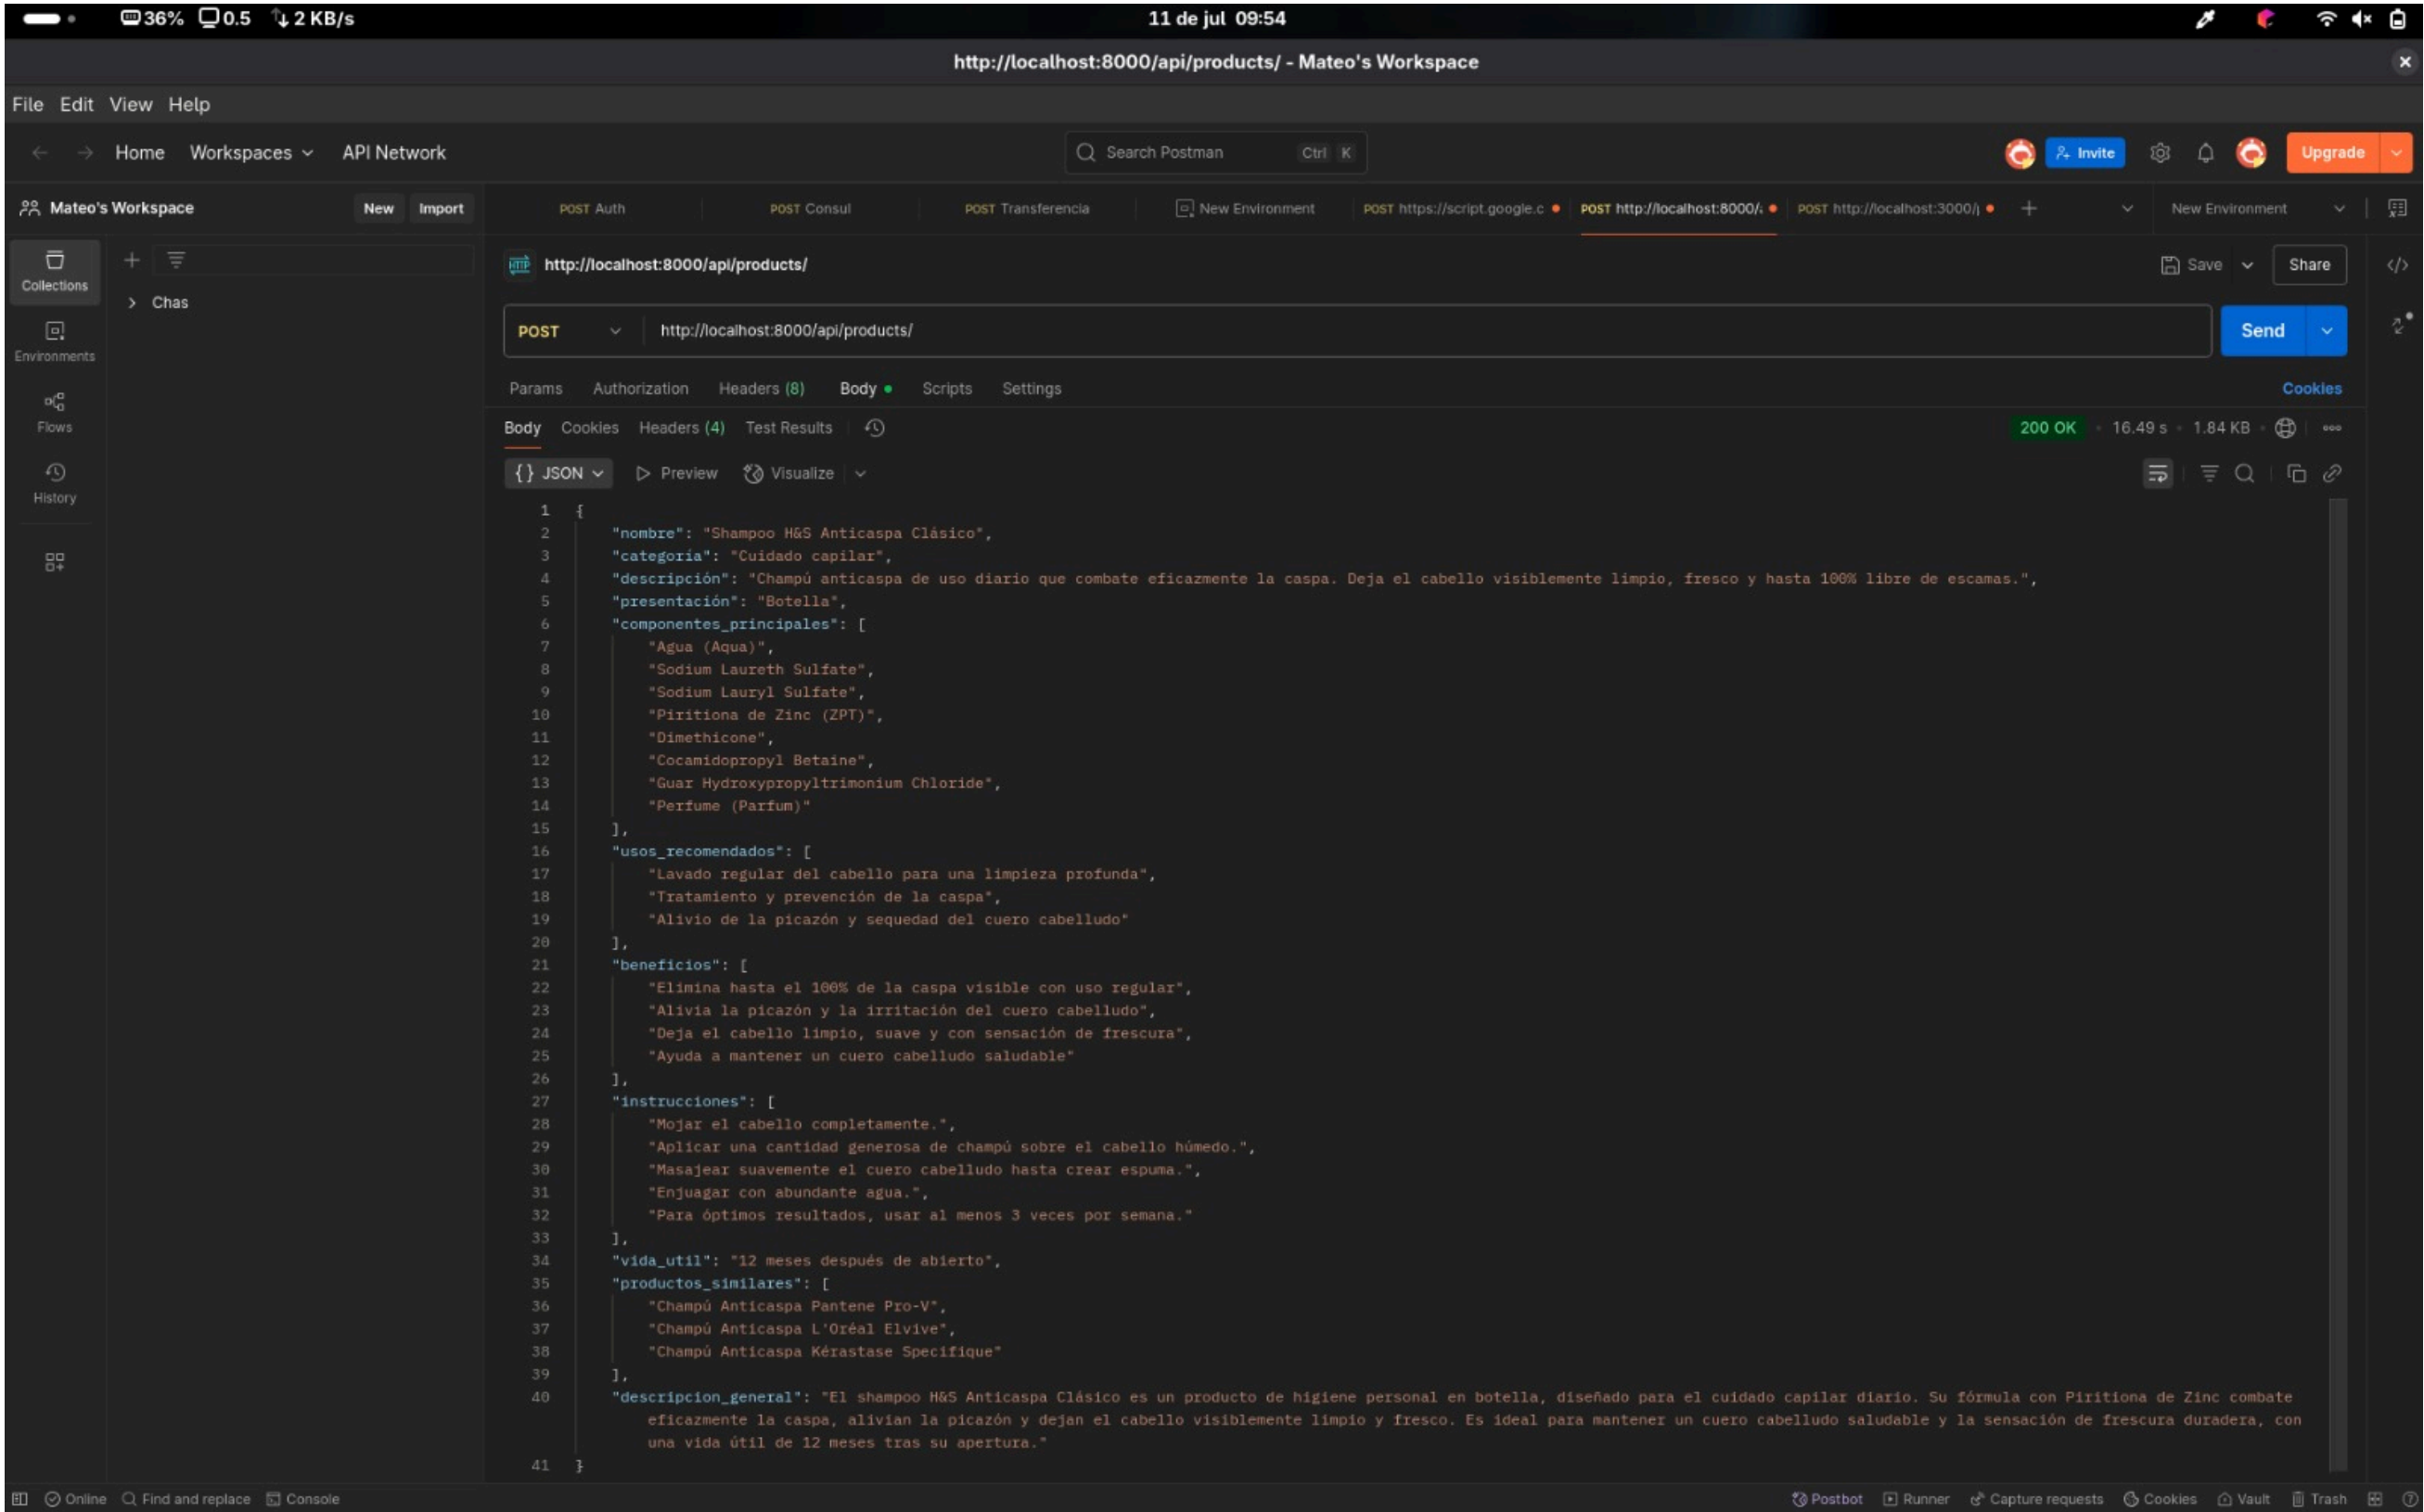
Utilizamos Vertex AI como interfaz para interactuar con modelos generativos de Google. A través de prompts con el nombre de una clase, obtenemos automáticamente información como su categoría, beneficios y descripciones útiles.

Uso de la api dentro de la app

1. Producto identificado por la CNN
2. Se consulta la API con el nombre del producto
3. Se recibe información detallada como:
 - Componentes principales
 - Uso recomendado
 - Beneficios
 - Instrucciones
 - Productos similares
 - Descripción General



PRUEBA DE LA API DE RECONOCIMIENTO



Referencias

Cuadernos

- <https://github.com/KarenS22/practica5IA.git>

Dataset

- <https://github.com/KarenS22/Dataset-SupermarketImages.git>